

DETEKSI AREA INFEKSI PNEUMONIA PADA CITRA RONTGEN DADA MENGUNAKAN ARSITEKTUR U-NET BERBASIS CONVOLUTIONAL NEURAL NETWORK (CNN)

Muhammad Hisyam¹, Dr. Tavipia Rumambi, SKom., MMSI.²

^{1,2}Fakultas Teknologi Industri, Universitas Gunadarma
Jl. Margonda Raya No. 100, Depok 16424, Jawa Barat

¹51422075@student.gunadarma.ac.id, ²tavipia@staff.gunadarma.ac.id

ABSTRAK

Tingginya angka kematian akibat pneumonia di seluruh dunia—terutama pada anak-anak, lansia, dan pasien imunokompromais—serta keterbatasan interpretasi manual citra Chest X-Ray (CXR) mendorong kebutuhan sistem deteksi otomatis berbasis deep learning. Penelitian ini membangun sistem segmentasi otomatis area infeksi pneumonia pada CXR menggunakan kerangka **CRISP-DM**. Strategi dual masking diterapkan: masker paru-paru dari model **PSPNet** (torchxrayvision) membatasi wilayah analisis, sementara masker bounding box RSNA menjadi ground truth pelatihan. Segmentasi dilakukan menggunakan arsitektur **U-Net dengan mekanisme atensi sCSE** (Spatial and Channel Squeeze-and-Excitation) dan backbone **EfficientNet-B3** pretrained ImageNet. Model dilatih pada dataset **RSNA Pneumonia Detection Challenge** (26.684 citra DICOM) menggunakan **Unified Focal Loss**, optimizer AdamW, Automatic Mixed Precision (AMP), dan akumulasi gradien. Keterjelasan model difasilitasi **Grad-CAM**, dan hasil diintegrasikan ke antarmuka web **Gradio** yang dapat diakses publik melalui **Cloudflare Tunnel**. Evaluasi kuantitatif menunjukkan Dice Coefficient **0,6234**, Precision **0,6868**, Recall **0,7082**, dan Specificity **0,9781**, membuktikan potensi sistem sebagai alat bantu skrining klinis yang efektif dan transparan.

Kata Kunci: Deep Learning, EfficientNet-B3, Pneumonia, sCSE, U-Net.

ABSTRACT

The high global mortality caused by pneumonia—particularly among children, the elderly, and immunocompromised patients—combined with limitations of manual chest X-ray (CXR) interpretation, drives the demand for automated deep learning-based detection systems. This study develops an automatic pneumonia infection segmentation system on CXR images following the **CRISP-DM** framework. A dual-masking strategy is applied: lung masks generated by **PSPNet** (torchxrayvision) constrain the analysis region, while RSNA bounding-box annotations serve as training ground truth. Segmentation is performed using a **U-Net with sCSE** (Spatial and Channel Squeeze-and-Excitation) **attention** and a **pre-trained EfficientNet-B3** backbone trained on the **RSNA Pneumonia Detection Challenge** dataset (26,684 DICOM images) using **Unified Focal Loss**, AdamW optimizer, Automatic Mixed Precision (AMP), and gradient accumulation. Model explainability is facilitated by **Grad-CAM**, and the system is integrated into a **Gradio** web interface accessible publicly via **Cloudflare Tunnel**. Quantitative evaluation yields a Dice Coefficient of **0.6234**, Precision of **0.6868**, Recall of **0.7082**, and Specificity of **0.9781**, demonstrating the system's potential as an effective and transparent clinical screening aid.

Keywords: Deep Learning, EfficientNet-B3, Pneumonia, sCSE, U-Net.

PENDAHULUAN

Pneumonia merupakan infeksi saluran pernapasan akut yang menyerang paru-paru dan menjadi salah satu penyebab kematian utama di tingkat global. Berdasarkan data *World Health Organization* (WHO), infeksi ini merenggut sekitar 2,5 juta jiwa di seluruh dunia pada tahun 2019, dengan porsi terbesar menyerang anak-anak di bawah usia lima tahun (World Health Organization, 2024). Di Indonesia, beban penyakit ini diperparah oleh keterbatasan tenaga ahli radiologi di daerah perifer (Said, 2018). Secara klinis, pneumonia terjadi saat patogen menginvasi alveoli paru-paru, memicu penumpukan eksudat yang mengganggu ventilasi (Seth et al., 2022).

Diagnosis pneumonia umumnya dilakukan melalui foto rontgen dada (*Chest X-Ray/CXR*). Meskipun efisien dari segi biaya dan dosis radiasi, interpretasi manual CXR memiliki kelemahan: beban kerja radiolog yang tinggi, serta pola infeksi pneumonia yang kadang menyerupai penyakit paru lain seperti edema atau efusi pleura, sehingga rawan terjadi kesalahan—terutama di fasilitas dengan keterbatasan sumber daya manusia.

Perkembangan *deep learning* berbasis *Convolutional Neural Network* (CNN) terbukti mampu menganalisis citra medis dengan akurasi tinggi. Arsitektur U-Net (Ronneberger et al., 2015) menjadi pilihan utama untuk segmentasi citra medis berkat kemampuannya mempertahankan detail spasial melalui *skip connections*.

Berbagai penelitian terdahulu (dirangkum pada Tabel 1) telah mengembangkan metode deteksi pneumonia berbasis *deep learning*, namun mengidentifikasi empat celah riset utama: (1) kurangnya strategi generalisasi berbasis *lung masking*; (2) keterbatasan lokalisasi lesi tanpa mekanisme atensi; (3) tidak adanya *pipeline* kuantifikasi klinis terintegrasi; dan (4) belum optimalnya efisiensi komputasi pada GPU terbatas.

Tabel 1. Perbandingan Penelitian Terdahulu Deteksi Pneumonia.

Peneliti	Tahun	Metode	Metrik Terbaik
Teixeira dkk.	2021	VGG + Lung Seg	Acc 94,1%
Degerli dkk.	2022	OSegNet (Op. Layer)	Dice 0,638
Farag dkk.	2020	MultiCheXNet MTL	AUC 0,94
Dang dkk.	2025	CAD-Unet (Capsule)	Dice 0,791*
Zhang dkk.	2023	CXR-Net E-D-E	AUC 0,963
Mallidi	2024	U-Net + VGG16	Dice 0,612
Kami	2026	U-Net sCSE + EffB3	Dice 0,623

*Dataset CT, bukan CXR.

Penelitian ini mengembangkan sistem yang menjawab celah tersebut dengan menggabungkan arsitektur U-Net dengan mekanisme atensi sCSE (Roy et al., 2018), *backbone* EfficientNet-B3 (Tan and Le, 2019), strategi *dual lung masking* berbasis PSPNet (Teixeira et al., 2021), Grad-CAM (Selvaraju et al., 2017), serta antarmuka web Gradio berbasis Cloudflare Tunnel (Cloudflare Inc., 2024).

Rumusan Masalah. Penelitian ini menjawab tiga pertanyaan: (1) Bagaimana membangun model deteksi pneumonia U-Net sCSE dengan *backbone* EfficientNet-B3 pada dataset RSNA? (2) Bagaimana pengaruh atensi sCSE dan *lung masking* terhadap performa deteksi? (3) Bagaimana membangun antarmuka web yang menyajikan Grad-CAM dan analisis kuantitatif secara transparan?

Tujuan. Menghasilkan alat bantu skrining awal (*triase*) berbasis web yang akurat, transparan, dan dapat diakses secara publik untuk membantu tenaga medis mendeteksi dan mengkuantifikasi area infeksi pneumonia pada CXR.

METODE PENELITIAN

Penelitian dilaksanakan menggunakan kerangka **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*), yang mencakup enam tahap iteratif: Pemahaman Bisnis, Pemahaman Data, Persiapan Data, Pemodelan, Evaluasi, dan Penerapan (Batta, 2020).


Alur Penelitian dan Arsitektur Sistem

Alur penelitian ditunjukkan pada Gambar 1. Citra CXR masukan terlebih dahulu diproses oleh modul *lung masking* berbasis PSPNet untuk memisahkan rongga paru dari organ luar (Teixeira et al., 2021; Azimi et al., 2022). Citra terpotong kemudian dimasukkan ke model U-Net sCSE dengan *encoder* EfficientNet-B3.



Gambar 1. Alur Penelitian Deteksi Pneumonia Berbasis CRISP-DM.

Arsitektur sistem terdiri dari empat modul terintegrasi (Gambar 2): (1) Modul Pra-pemrosesan & *Lung Masking* PSPNet; (2) Modul Segmentasi U-Net sCSE; (3) Modul Keterangan Grad-CAM; dan (4) Modul Antarmuka Web Gradio.




Gambar 2. Arsitektur Sistem Deteksi Pneumonia Empat Modul.


Arsitektur U-Net dengan Atensi sCSE dan Backbone EfficientNet-B3

Arsitektur U-Net (Gambar 3) membentuk struktur simetris huruf “U” yang terdiri atas jalur kontraksi (*encoder*) dan ja-

lur ekspansi (*decoder*) yang dihubungkan oleh *skip connections* (Ronneberger et al., 2015). Sebagai *encoder*, digunakan EfficientNet-B3 yang memanfaatkan teknik *Compound Scaling* untuk menyeimbangkan kedalaman, lebar, dan resolusi jaringan secara bersamaan (Tan and Le, 2019) (Gambar 4).




Gambar 3. Struktur Arsitektur U-Net dengan *Skip Connections*.



Gambar 4. Konsep *Compound Scaling* pada EfficientNet-B3.

Mekanisme atensi *Spatial and Channel Squeeze-and-Excitation* (sCSE) diin-

tegrasikan pada setiap blok *decoder* (Roy et al., 2018) (Gambar 5). Modul sCSE menggabungkan atensi saluran (cSE—channel-wise global average pooling + MLP) dan atensi spasial (sSE—konvolusi 1×1) secara paralel, yang secara adaptif menonjolkan fitur lesi *Ground-Glass Opacities* (GGO) sekaligus menekan fitur tulang rusuk yang redundan.



Gambar 5. Alur Kerja Modul Atensi sCSE (cSE + sSE secara Paralel).

Total parameter model: **13.222.695**. Kepala bantu (*auxiliary supervision head*) ditambahkan dengan bobot $\lambda_{aux} = 0,3$ untuk memperkuat sinyal gradien pada lapisan dalam.

Fungsi Kerugian Unified Focal Loss

Untuk mengatasi ketimpangan kelas ekstrem antara piksel paru sehat yang mendominasi dengan piksel infeksi pneumonia yang jauh lebih sedikit, digunakan **Unified Focal Loss** (Yeung et al., 2022):

$$L_{unified} = 0,5 \cdot L_{Focal} + 0,5 \cdot L_{FT} \quad (1)$$

di mana L_{Focal} mengurangi bobot piksel latar belakang yang mudah diprediksi dengan faktor $(1 - p_t)^\gamma$ ($\gamma = 2,0$; $\alpha = 0,25$), dan L_{FT} (*Focal Tversky Loss*) mengoptimalkan indeks Tversky dengan $\alpha = 0,3$ (penalti *false negative*) dan $\beta = 0,7$ (penalti *false positive*) untuk menekan tingkat alarm palsu.

Dataset RSNA dan Pra-pemrosesan

Dataset yang digunakan adalah **RSNA Pneumonia Detection Challenge** yang terdiri dari 26.684 citra DICOM. Distribusi kelas dataset ditunjukkan pada Tabel 2.

Tabel 2. Distribusi Kelas Dataset RSNA Pneumonia.

Kelas	Jumlah	Persentase
Lung Opacity (Pneumonia)	6.012	22,5%
No Lung Opacity / Not Normal	7.210	27,1%
Normal	13.462	50,4%
Total	26.684	100%

Dataset dibagi secara stratifikasi pada level pasien: **5.344 pasien latih** dan **1.336 pasien validasi** (rasio 80:20) untuk mencegah kebocoran data. Pra-pemrosesan mencakup: (1) ekstraksi array piksel dari berkas DICOM; (2) normalisasi intensitas Min-Max dan penyesuaian ke 512×512 piksel; (3) normalisasi mean/std ImageNet; (4) segmentasi paru otomatis menggunakan PSPNet (*threshold* 0,5); dan (5) konversi koordinat *bounding box* menjadi masker biner 512×512 .

Augmentasi data medis diterapkan menggunakan pustaka *Albumentations* (Seth et al., 2022), meliputi: *Ho-*

izontal/Vertical Flip, *ShiftScaleRotate* ($\leq 10^\circ$), *RandomBrightnessContrast*, *RandomGamma*, *CLAHE*, *GaussNoise*, *GridDropout*, dan *CoarseDropout*.

Konfigurasi Pelatihan

Pelatihan menggunakan strategi dua fase: (1) Fase *warmup* (Epoch 1–12): *encoder* dibekukan sehingga *decoder* beradaptasi tanpa merusak bobot pra-latih; (2) Fase *fine-tuning* (Epoch 13+): seluruh jaringan dilatih *end-to-end* dengan *learning rate* diferensial. Konfigurasi lengkap disajikan pada Tabel 3.

Tabel 3. Konfigurasi Pelatihan Model U-Net sCSE.

Parameter	Nilai
Optimizer	AdamW
Learning Rate (Decoder)	4×10^{-4}
Learning Rate (Encoder)	8×10^{-6}
Weight Decay	5×10^{-4}
Scheduler	Cosine Annealing ($\eta_{\min} = 10^{-6}$)
Batch Size (Fisik)	8
Akumulasi Gradien	4 langkah (batch efektif 32)
Mixed Precision	AMP FP16
Exponential Moving Average	EMA (<i>decay</i> 0,999)
Early Stopping	<i>Patience</i> 35 epoch
Maksimum Epoch	100
Fase Warmup	12 epoch (<i>encoder</i> dibekukan)
Hardware	NVIDIA RTX 3070 (8 GB VRAM)

Metrik Evaluasi dan Test-Time Augmentation


Performa model diukur menggunakan empat metrik segmentasi: *Dice Coefficient*, *Precision*, *Recall* (Sensitivitas), dan *Specificity*. Semua metrik dihitung sebagai rata-rata per sampel (*per-image mean*) atas 1.336 citra validasi.

Untuk meningkatkan kekokohan prediksi, diterapkan **Test-Time Augmentation** (TTA) yang merata-rata prediksi dari


tiga transformasi berbeda: citra asli, *horizontal flip*, dan *vertical flip*.

Pemodelan UML Sistem

Interaksi tenaga medis dengan aplikasi dirancang menggunakan *Use Case Diagram* (Gambar 6) yang menyediakan enam fungsi utama: unggah citra (DICOM/PNG/JPG), atur *threshold*, analisis file, lihat visualisasi *overlay & Grad-CAM*, lihat laporan keparahan & lateralitas, dan *reset*. Alur logika inferensi dimodelkan melalui *Activity Diagram* (Gambar 7).



Gambar 6. *Use Case Diagram* Antarmuka Web Gradio (6 Use Case).




Gambar 7. *Activity Diagram* Alur Inferensi dan Analisis Sistem.

PEMBAHASAN

Hasil Pelatihan Model

Proses pelatihan berlangsung selama **81 epoch** dan dihentikan secara otomatis oleh mekanisme *early stopping* (patience 35). Model terbaik (*best checkpoint*) diperoleh pada **Epoch ke-46** dengan nilai *Validation Loss* terendah sebesar **0,2755** (*Train Loss* = 0,2659) dan *Validation Dice* sebesar 0,6203. Kurva penurunan *loss* selama 81 epoch ditunjukkan pada Gambar 8.



Gambar 8. Kurva *Loss* Pelatihan dan Validasi selama 81 Epoch (*Best Model* Epoch 46, Val Loss = 0,2755).

Pada Epoch 1–12 (*warmup*), *encoder*

dibekukan sehingga *decoder* dapat beradaptasi tanpa merusak bobot pra-latih ImageNet. Setelah *encoder* dibuka pada Epoch 13, terjadi penurunan *loss* validasi secara tajam, membuktikan efektivitas *transfer learning* EfficientNet-B3 sebagai *encoder* yang kaya fitur.

Evaluasi Kuantitatif

Hasil evaluasi kuantitatif model terbaik pada 1.336 citra validasi (metode rata-rata per sampel/*per-image mean*) dirangkum pada Tabel 4.


Tabel 4. Hasil Evaluasi Kuantitatif Model U-Net sCSE (Epoch 46).

Metrik	Nilai	Interpretasi
<i>Dice Coefficient</i>	0,6234	Kemiripan prediksi vs <i>ground truth</i>
<i>Precision</i>	0,6868	Kebenaran area yang diprediksi pneumonia
<i>Recall</i>	0,7082	Sensitivitas deteksi lesi pneumonia
<i>Specificity</i>	0,9781	Kebenaran identifikasi area paru sehat
<i>Validation Loss</i>	0,2755	Nilai <i>Unified Focal Loss</i>

Keseimbangan antara *Recall* (70,82%) dan *Precision* (68,68%) menunjukkan model sangat sensitif dalam mendeteksi bercak pneumonia sekaligus efektif menekan *false alarm*. Nilai *Specificity* yang sangat tinggi (97,81%) memastikan area paru sehat tidak salah diarsir, yang sangat penting dalam konteks skrining klinis untuk meminimalkan tindak lanjut yang tidak perlu.

Confusion Matrix Tingkat Piksel

Matriks kebingungan (*confusion matrix*) pada tingkat piksel dari total 350.224.384 piksel validasi ditunjukkan pada Gambar 9. Model berhasil mengenali **20.745.986 piksel TP** dan **312.284.691 piksel TN**, dengan *false positive* sebanyak 7.198.145 piksel dan *false negative* sebanyak 9.995.562 piksel.




Gambar 9. *Confusion Matrix* Tingkat Piksel pada Data Validasi (Total 350,2 Juta Piksel).

Analisis pengaruh nilai ambang batas (*threshold*) prediksi menunjukkan bahwa nilai **0,65** merupakan titik optimal yang menyeimbangkan *Recall* dan *Precision* pada kurva ROC, dipilih sebagai *default threshold* pada antarmuka web.

Visualisasi Segmentasi dan Analisis Per Kasus

Visualisasi komparatif segmentasi pada empat sampel citra uji (Gambar 10) mencakup: (a) citra asli; (b) hasil *lung masking* PSPNet; (c) *overlay* segmentasi merah; dan (d) *probability heatmap*.



Gambar 10. Visualisasi Komparatif Hasil Segmentasi: (1) Normal, (2) Pneumonia Virus Ringan, (3) Pneumonia Virus Sedang, (4) Pneumonia Bakteri Berat.

Analisis visual menunjukkan: (1) **Normal**: masker prediksi bersih (0% infeksi) dan *heatmap* biru merata, tanpa *false positive*; (2) **Pneumonia Ringan**: arsir merah minor ($\leq 5\%$) terlokalisasi di satu lobus; (3) **Pneumonia Sedang**: infeksi bilateral (5%–15%) tersebar di kedua belah paru; (4) **Pneumonia Berat**: arsir merah luas ($>15\%$) menutupi area konsolidasi bakteri yang pekat. Kegagalan deteksi (*false negative*) umumnya terjadi pada lesi di batas jantung/hilus (*cardiac border/hilar*) akibat kesamaan intensitas dengan struktur normal.

Analisis Keterjelasan Model (Grad-CAM)

Visualisasi Grad-CAM (Selvaraju et al., 2017) dihitung dari la-

pisan konvolusi terakhir *encoder* EfficientNet-B3 dan diwarnai menggunakan skala termal medis *INFERNO* (cv2.COLORMAP_INFERNO). Peta aktivasi secara konsisten menunjukkan warna kuning cerah/putih pada pusat *hotspot* opasitas abnormal serta merah/oranye pada daerah perilesional, sementara jaringan paru sehat tetap berwarna gelap. Hal ini membuktikan bahwa model membuat keputusan berdasarkan fitur medis yang valid (bercak paru) dan bukan dari artefak radiologi (teks, kabel elektroda, atau tepi tulang rusuk). Hal ini meningkatkan kepercayaan klinis terhadap prediksi model.

Analisis Keparahan dan Lateralitas Infeksi


Sistem mengimplementasikan kuantifikasi klinis berbasis rasio area infeksi terhadap area paru, yang diklasifikasikan ke dalam lima tingkat keparahan (Tabel 5). Selain itu, distribusi spasial infeksi dianalisis untuk menentukan lateralitas: *Left*, *Right*, atau *Bilateral*.

Tabel 5. Klasifikasi Tingkat Keparahan Infeksi Pneumonia.

Tingkat	Rasio Infeksi	Interpretasi Klinis
Normal	0%	Tidak terdeteksi infeksi
Ringan	$\leq 5\%$	Lesi fokal kecil, satu lobus
Sedang	5%–15%	Lesi multilobar atau bilateral
Berat	15%–30%	Konsolidasi ekstensif
Kritis	$>30\%$	Penyebaran menyeluruh


Demonstrasi Antarmuka Web Gradio dan Deployment

Antarmuka web berbasis Gradio berhasil dibangun (Gambar 11). Pengguna dapat mengunggah citra rontgen (DICOM/PNG/JPEG), menggeser *threshold* (0,1–0,9), dan memperoleh empat keluaran visual (*overlay*, Grad-CAM INFERNO, *lung mask*, *isolated lung*) serta laporan kuantitatif (status diagnosis, derajat keparahan, persentase infeksi, lateralitas, dan skor rerata kepercayaan) dalam waktu inferensi **1–3 detik** pada GPU RTX 3070.



Gambar 11. Tampilan Antarmuka Web Gradio dan Hasil Analisis *Real-Time*.

Penyebaran publik dilakukan menggunakan **Cloudflare Tunnel** (cloudflared) (Cloudflare Inc., 2024) (Gambar 12). Daemon *cloudflared* membuka terowongan keluar terenkripsi (HTTPS/QUIC) ke jaringan *edge* Cloudflare di <https://grad.mhisyam.com>, mengatasi pembatasan IP publik tanpa memerlukan *port forwarding* pada *router*, sehingga GPU lokal dapat melayani pengguna eksternal secara aman.



Gambar 12. Skema Penyebaran Web Gradio Menggunakan Cloudflare Tunnel.

Pengujian Fungsionalitas (Black-Box Testing)

Pengujian fungsionalitas antarmuka menggunakan metode *black-box testing* mencakup delapan skenario: (1) unggah berkas DICOM; (2) unggah berkas PNG/JPEG; (3) atur nilai *threshold*; (4) eksekusi analisis; (5) ekstraksi paru PSP-Net; (6) segmentasi & Grad-CAM; (7) laporan metrik keparahan; dan (8) penanganan galat (*error handling*). Seluruh delapan skenario dinyatakan **BERHASIL** dengan hasil sesuai harapan.

Studi Ablasi Komponen

Studi ablasi (*ablation study*) dilakukan untuk mengukur kontribusi setiap komponen utama sistem. Hasil ditunjukkan pada Tabel 6.

Tabel 6. Studi Ablasi: Dampak Komponen terhadap Performa.

Konfigurasi	Val Loss	Dice
<i>Baseline</i> (tanpa pra-latih)	0,3212	0,581
+ Bobot Pra-latih ImageNet	0,2944	0,608
+ Atensi sCSE	0,2831	0,615
+ <i>Unified Focal Loss</i>	0,2789	0,619
+ <i>Lung Masking</i> PSPNet	0,2767	0,621
+ AMP & Akumulasi Gradien	0,2761	0,622
+ Augmentasi (Full Model)	0,2755	0,623

Studi ablasi mengonfirmasi bahwa: (1) Bobot pra-latih ImageNet menurunkan *val loss* dari 0,3212 ke 0,2944; (2) Atensi sCSE meningkatkan presisi batas lesi; (3) *Unified Focal Loss* menjaga sensitivitas *Recall* (70,82%); dan (4) *Lung Masking* PSPNet mengeliminasi *false positive* di luar organ paru secara efektif (Bassi and Attux, 2022).

PENUTUP

Kesimpulan. Penelitian ini berhasil membangun sistem deteksi dan segmentasi otomatis area infeksi pneumonia menggunakan arsitektur **U-Net dengan atensi sCSE** dan *backbone* **EfficientNet-B3**. Model mencapai kinerja tinggi pada data validasi RSNA dengan *Dice Coefficient* **0,6234**, *Precision* **0,6868**, *Recall* **0,7082**, dan *Specificity* **0,9781**. Strategi

dual lung masking berbasis PSPNet terbukti efektif mencegah *shortcut learning* dan menekan *false positive* di luar organ paru. Mekanisme atensi sCSE meningkatkan akurasi batas lesi. Fungsi kerugian *Unified Focal Loss* berhasil menyeimbangkan sensitivitas dan spesifisitas pada kondisi data yang sangat tidak seimbang. Visualisasi Grad-CAM memberikan transparansi medis yang terverifikasi. Antarmuka web Gradio yang dipublikasikan melalui Cloudflare Tunnel mampu menyajikan analisis kuantitatif (5 tingkat keparahan dan lateralitas) serta visualisasi klinis secara *real-time* (1–3 detik), siap digunakan sebagai alat bantu skrining awal (*triase*) medis.

Saran. Untuk pengembangan selanjutnya: (1) Menggunakan dataset dengan anotasi manual tingkat piksel (*pixel-level*) langsung dari spesialis radiologi untuk meningkatkan kualitas *ground truth*; (2) Mengeksplorasi arsitektur berbasis *Vision Transformer* (ViT) untuk perbandingan dengan pendekatan berbasis CNN; (3) Melakukan uji validasi klinis menggunakan data rontgen dari rumah sakit lokal di Indonesia; serta (4) Mengintegrasikan aplikasi web dengan sistem *Picture Archiving and Communication System* (PACS) rumah sakit.

PUSTAKA

Azimi, H., Zhang, J., Xi, P., Asad, H., Ebadi, A., Tremblay, S., and Wong, A. (2022). Improving classification model performance on chest x-rays thro-

- ugh lung segmentation. *arXiv preprint arXiv:2202.10971*.
- Bassi, P. R. A. S. and Attux, R. (2022). Covid-19 detection using chest x-rays: is lung segmentation important for generalization? *Research on Biomedical Engineering*, 38(2):343–351.
- Batta, H. (2020). A review on machine learning concepts with applications. *International Journal of Innovative Science and Research Technology*, pages 1404–1408.
- Cloudflare Inc. (2024). Cloudflare tunnel: Connect applications and networks securely without opening ports.
- Ronneberger, O., Fischer, P., and Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pages 234–241. Springer.
- Roy, A. G., Wachinger, C., and Shearar, M. (2018). Recalibrating fully convolutional networks with spatial and channel “Squeeze & Excitation” blocks. *IEEE Transactions on Medical Imaging*, 37(10):2349–2360.
- Said, M. (2018). Pneumonia pada anak. *Sari Pediatri*, 15(6):356–365.
- Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., and Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. In *IEEE International Conference on Computer Vision (ICCV)*, pages 618–626.
- Seth, J., Lokwani, R., Kulkarni, V., Pant, A., and Kharat, A. (2022). Reducing labelled data requirement for pneumonia segmentation using image augmentations. In *Lecture Notes in Networks and Systems*, volume 314, pages 307–315.
- Tan, M. and Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. In *International Conference on Machine Learning (ICML)*, pages 6105–6114.
- Teixeira, L. O., Pereira, R. M., Bertolini, D., Oliveira, L. S., Nanni, L., Cavalcanti, G. D. C., and Costa, Y. M. G. (2021). Impact of lung segmentation on the diagnosis and explanation of covid-19 in chest x-ray images. *Sensors*, 21(21):7116.
- World Health Organization (2024). Pneumonia in children and global health estimates.
- Yeung, M., Sala, E., Schönlieb, C.-B., and Rundo, L. (2022). Unified focal loss: Generalising dice and cross entropy-based losses to handle class imbalanced medical image segmentation. *Computerized Medical Imaging and Graphics*, 95:102026.